

Predição da Resistência à Compressão de Concretos Utilizando Aprendizado de Máquina: Treino, Explicabilidade e Otimização

André de A. Caetano¹ & Ronaldo C. Prati¹

¹Centro de Matemática, Computação e Cognição (CMCC)
Universidade Federal do ABC (UFABC)
Av. dos Estados, 5001 – 09210-580 – Santo André – SP – Brazil

Abstract. *This work compares two machine learning approaches, a Multilayer Perceptron (MLP) and a Gradient Boosting model (XGBoost), for predicting concrete compressive strength from mixture composition. Beyond predictive performance, the study investigates what each model learns through feature importance and SHAP analysis, and uses a Genetic Algorithm (GA) to search for mixtures that maximize predicted strength. The results show that XGBoost outperforms the MLP on this tabular dataset, that both models capture physically consistent patterns, and that optimization without domain constraints leads to unrealistic mixtures, a limitation that is more severe when the GA is guided by the MLP than by XGBoost.*

Resumo. *Este trabalho compara duas abordagens de aprendizado de máquina, uma rede neural do tipo Multilayer Perceptron (MLP) e um modelo de Gradient Boosting (XGBoost), para prever a resistência à compressão do concreto a partir da composição da mistura. Além do desempenho preditivo, o estudo investiga o que cada modelo aprendeu por meio de análise de importância de variáveis e SHAP, e utiliza um Algoritmo Genético (GA) para buscar misturas que maximizem a resistência prevista. Os resultados mostram que o XGBoost supera a MLP neste dataset tabular, que ambos os modelos capturam padrões fisicamente coerentes, e que a otimização sem restrições de domínio leva a misturas irrealistas, uma limitação mais severa quando o GA é guiado pela MLP do que pelo XGBoost.*

1. Descrição do Problema

A resistência à compressão é uma das propriedades mais importantes do concreto, sendo diretamente influenciada pela composição da mistura e pelo tempo de cura. A relação entre essas variáveis é conhecida por ser altamente não linear, o que dificulta a obtenção de modelos analíticos precisos e motiva o uso de modelos de aprendizado de máquina para essa tarefa [Yeh 1998, Mehta and Monteiro 2014].




Figura 1. (a) Componentes que formam a mistura de concreto e (b) esquema do ensaio de resistência à compressão, no qual uma carga é aplicada até a ruptura do corpo de prova. Esquema gerado com auxílio de inteligência artificial, elaborado especificamente para este trabalho por não terem sido encontradas imagens de domínio público que representassem adequadamente a mensagem pretendida.

O objetivo deste trabalho é duplo. Primeiro, investigar a capacidade de uma rede neural do tipo MLP em aprender a relação entre a composição do concreto e sua resistência mecânica, comparando seu desempenho com um baseline de Gradient Boosting (XGBoost), que costuma apresentar desempenho superior em problemas de regressão tabular de porte pequeno a médio. Segundo, ir além da métrica de erro e entender o que cada modelo efetivamente aprendeu, utilizando essa compreensão como base para uma etapa de otimização, na qual um Algoritmo Genético busca, dentro do espaço de composições possíveis, a mistura que maximiza a resistência prevista pelos modelos treinados.

Formalmente, o problema é definido como uma tarefa de regressão supervisionada. Dado um vetor de entrada $x \in R^8$, contendo as quantidades de cimento, escória de alto forno, cinza volante, água, superplastificante, agregado grauído, agregado miúdo e idade de cura, o objetivo é aprender uma função $f(x)$ que aproxime a resistência à compressão real y , medida em MPa, minimizando o erro quadrático médio entre a previsão e o valor observado [Hastie et al. 2009].

Foi utilizado o dataset público de composição de concreto disponível no Kaggle, correspondente ao dataset clássico UCI/Yeh Concrete Compressive Strength, com 1030 amostras e 8 variáveis de entrada, sem valores ausentes. A escolha por um dataset simples e já limpo foi deliberada, uma vez que o foco do trabalho não é a etapa de preparação

de dados, mas sim a comparação entre diferentes abordagens de modelagem e a análise aprofundada do comportamento de cada uma [I-Cheng Yeh 1998].

A Tabela 1 descreve o significado de cada variável, uma vez que os nomes das colunas no dataset original estão em inglês e de forma abreviada [I-Cheng Yeh 1998, Yeh 1998].

Tabela 1. Descrição das variáveis do dataset.

Coluna	Significado	Unidade
cement	Teor de cimento Portland	kg/m ³
slag	Teor de escória de alto forno	kg/m ³
ash	Teor de cinza volante	kg/m ³
water	Teor de água	kg/m ³
superplastic	Teor de superplastificante	kg/m ³
coarseagg	Teor de agregado graúdo (brita)	kg/m ³
fineagg	Teor de agregado miúdo (areia)	kg/m ³
age	Idade de cura do concreto	dias
strength	Resistência à compressão (variável alvo)	MPa

2. Abordagem

2.1. Pré-processamento e protocolo experimental

O conjunto de dados foi dividido em treino e teste, reservando 15% das amostras (155 de 1030) para avaliação final, mantida intocada durante todo o processo de escolha de hiperparâmetros. As variáveis de entrada foram normalizadas com *StandardScaler*, ajustado exclusivamente sobre o conjunto de treino para evitar vazamento de informação do teste. Para a MLP, a variável alvo também foi normalizada, sendo desnormalizada no momento da avaliação das métricas.

A seleção de hiperparâmetros, tanto para a MLP quanto para o XGBoost, foi conduzida por meio de validação cruzada com 5 folds (K-Fold), aplicada exclusivamente sobre o conjunto de treino. Essa etapa foi usada apenas para ranquear configurações, sendo o modelo final treinado uma única vez sobre todo o conjunto de treino, com avaliação única e final sobre o conjunto de teste, de forma a evitar que a escolha de hiperparâmetros fosse enviesada pelos dados de teste.

2.2. Arquitetura da MLP

A MLP foi implementada em PyTorch, com camadas ocultas totalmente conectadas, ativação não linear configurável, dropout como regularização e otimizador Adam. O treinamento utilizou parada antecipada (*early stopping*), interrompendo o treino quando a perda de validação deixava de melhorar por um número fixo de épocas consecutivas, o que evita overfitting e reduz o custo computacional da busca de hiperparâmetros [Paszke et al. 2019, Kingma and Ba 2015].

A busca de hiperparâmetros variou função de ativação (ReLU, GELU, ELU, LeakyReLU, Tanh), número e tamanho das camadas ocultas, taxa de dropout, taxa de aprendizado e número máximo de épocas, utilizando amostragem aleatória do espaço de

configurações em vez de busca em grade completa, dado o alto número de combinações possíveis. A configuração final selecionada foi uma MLP com duas camadas ocultas de 128 neurônios, ativação ReLU, dropout de 0.15 e taxa de aprendizado de 0.001 [Srivastava et al. 2014, Prechelt 1998].

2.3. Baseline com XGBoost

Como baseline, foi utilizado um modelo de Gradient Boosting (XGBoost), que combina múltiplas árvores de decisão rasas de forma sequencial, cada uma corrigindo o erro residual da anterior. Diferente da MLP, o XGBoost não exige normalização das variáveis de entrada, sendo treinado diretamente sobre os dados originais. A busca de hiperparâmetros seguiu o mesmo protocolo de K-Fold utilizado na MLP, variando número de estimadores, profundidade máxima das árvores, taxa de aprendizado e frações de subamostragem de linhas e colunas [Chen and Guestrin 2016].

2.4. Interpretabilidade

Para entender o que o modelo de melhor desempenho efetivamente aprendeu, foi aplicada a técnica SHAP (SHapley Additive exPlanations) sobre o XGBoost final, complementando a importância de variáveis nativa do modelo. O SHAP atribui a cada variável sua contribuição real para cada previsão individual, com base em teoria dos jogos, permitindo tanto uma visão agregada de importância quanto a análise de relações não lineares entre cada variável e a resistência prevista [Shapley 1953].

2.5. Otimização com Algoritmo Genético

Na etapa final, foi implementado um Algoritmo Genético (GA) que utiliza o modelo treinado como função de avaliação, buscando a composição de mistura que maximiza a resistência prevista. A idade de cura foi fixada em 30 dias, valor de referência para ensaios de resistência do concreto, de forma que a otimização incidisse exclusivamente sobre a proporção dos materiais, e não sobre o tempo de cura [Jin 2011].

Uma primeira busca, sem restrições além dos limites individuais de cada variável observados no dataset, revelou que o GA converge para combinações estatisticamente incomuns, com múltiplas variáveis simultaneamente em seus extremos, resultando em previsões acima do máximo observado no dataset. Para corrigir esse comportamento, foi implementada uma segunda versão do GA, incorporando duas restrições de domínio: um teto para o total de material cimentício (soma de cimento, escória e cinza volante) e um piso para a razão entre água e material cimentício, ambos definidos pelos valores extremos observados no próprio dataset. Por fim, o mesmo experimento de busca livre foi repetido utilizando a MLP como função de avaliação, em vez do XGBoost, para comparar o comportamento dos dois modelos diante de extrapolação.

3. Resultados

3.1. Análise exploratória

A Figura 2 apresenta a distribuição da variável alvo e a matriz de correlação entre as variáveis. A distribuição da resistência é assimétrica à direita, concentrada entre 20 e 50 MPa. Nenhuma variável apresenta correlação linear muito forte isoladamente com

a resistência, sendo a maior o cimento, com 0.50, o que já sugere que a relação entre composição e resistência é predominantemente não linear.




Figura 2. Distribuição da resistência à compressão e matriz de correlação entre as variáveis do dataset. Autoria própria.

3.2. Comparação entre MLP e XGBoost

A Tabela 2 apresenta as oito melhores configurações encontradas nas duas rodadas de busca de hiperparâmetros da MLP, ordenadas por RMSE médio obtido via validação cruzada de 5 folds no conjunto de treino.

Tabela 2. Melhores configurações de MLP encontradas na busca de hiperparâmetros, com RMSE médio via K-Fold no conjunto de treino.

Ativação	Camadas ocultas	Dropout	Learning rate	RMSE (MPa)
ReLU	(128, 128)	0.15	0.001	4.668
ReLU	(256, 256, 256, 256)	0.15	0.001	4.690
ReLU	(256, 256, 256, 256)	0.3	0.001	4.793
GELU	(64, 32)	0.15	0.01	4.883
GELU	(64, 32)	0.15	0.01	4.891
LeakyReLU	(256,)	0.15	0.01	4.908
GELU	(256, 256, 256, 256)	0.15	0.001	4.911
ReLU	(64, 32)	0.15	0.001	4.941

Tabela 3. Comparação de desempenho entre MLP e XGBoost no conjunto de teste.

Modelo	RMSE (MPa)	MAE (MPa)	R^2
MLP	4.909	3.347	0.914
XGBoost	4.124	2.713	0.939

O XGBoost superou a MLP em todas as métricas avaliadas, resultado consistente com o comportamento amplamente documentado na literatura de aprendizado de máquina, segundo o qual métodos de Gradient Boosting tendem a superar redes neurais em conjuntos de dados tabulares de porte pequeno a médio, como é o caso deste dataset,

com pouco mais de mil amostras. A Figura 3 apresenta os gráficos de valores previstos contra valores reais para os dois modelos.

Um resultado interessante da busca de hiperparâmetros, evidenciado na Tabela 2, é que a MLP atingiu uma espécie de piso de desempenho em torno de 4.7 a 4.9 MPa de RMSE, independentemente de variações relativamente amplas em função de ativação (testadas ReLU, GELU, ELU, LeakyReLU e Tanh), profundidade e largura da rede (de uma única camada de 64 neurônios até quatro camadas de 256) e taxa de dropout. Ao todo, 58 configurações distintas foram avaliadas em duas rodadas de busca, e as oito melhores ficaram concentradas em uma faixa de apenas 0.27 MPa entre si, o que indica que o ajuste fino de hiperparâmetros já havia esgotado boa parte do ganho possível dentro dessa arquitetura de modelo. Ainda assim, mesmo a melhor configuração da MLP (RMSE de 4.668 MPa via K-Fold) não foi capaz de alcançar o desempenho do XGBoost, cujas primeiras tentativas de busca de hiperparâmetros, antes mesmo de qualquer ajuste refinado, já produziam RMSE abaixo desse piso. Isso reforça que a diferença de desempenho entre os dois modelos não decorre de uma escolha de hiperparâmetro subótima para a MLP, mas de uma limitação mais estrutural do tipo de modelo diante deste conjunto de dados tabular, corroborando a expectativa da literatura mencionada anteriormente.

O XGBoost superou a MLP em todas as métricas avaliadas, resultado consistente com o comportamento amplamente documentado na literatura de aprendizado de máquina, segundo o qual métodos de Gradient Boosting tendem a superar redes neurais em conjuntos de dados tabulares de porte pequeno a médio, como é o caso deste dataset, com pouco mais de mil amostras. A Figura 3 apresenta os gráficos de valores previstos contra valores reais para os dois modelos.




Figura 3. Valores previstos contra valores reais de resistência à compressão no conjunto de teste, para (a) a MLP e (b) o XGBoost. Autoria própria.

3.3. Interpretabilidade com SHAP

A análise de importância de variáveis, apresentada na Figura 4, mostrou a idade de cura e o teor de cimento como as variáveis mais relevantes para a previsão do XGBoost, segui-

das pelo teor de água. Esse resultado é particularmente interessante quando comparado à matriz de correlação da Figura 2, uma vez que a idade apresentava correlação linear relativamente fraca com a resistência (0.33, contra 0.50 do cimento), mas se destaca como a variável mais importante segundo o SHAP. A explicação está na natureza não linear da relação entre idade e resistência, com ganho rápido nas primeiras semanas de cura seguido de estabilização, padrão capturado pelo gráfico de dependência da Figura 5, mas subestimado pela correlação linear simples, que só é sensível a relações em linha reta.




Figura 4. Importância média das variáveis segundo os valores de SHAP. Autoria própria.




Figura 5. Gráficos de dependência do SHAP para as variáveis (a) idade de cura e (b) teor de água, evidenciando a relação não linear entre idade e resistência. Autoria própria.

As variáveis de agregado graúdo e miúdo, além da cinza volante, apresentaram menor importância relativa, resultado condizente com a literatura de engenharia de mate-

riais, segundo a qual o agregado atua principalmente como material de preenchimento na mistura, sendo a resistência controlada majoritariamente pela pasta de cimento e pela qualidade da ligação entre pasta e agregado [Mehta and Monteiro 2014]. O mesmo padrão de importância, com idade e cimento à frente das demais variáveis, foi reportado em estudos que aplicaram SHAP sobre o mesmo dataset utilizando outros modelos baseados em árvores [Elshaarawy et al. 2024, Elhishi et al. 2023].




Figura 6. Explicação individual (force plot) para a amostra 67 do conjunto de teste. Autoria própria.

A Figura 6 ilustra como essas contribuições se combinam em uma previsão individual, para a amostra 67 do conjunto de teste. Nesse caso, a previsão do modelo ($f(x) = 46.24$ MPa) ficou acima do valor médio de referência do modelo (próximo de 37 MPa), impulsionada principalmente por uma idade de cura elevada (90 dias), um teor de cimento relativamente alto (393 kg/m³) e um valor elevado de agregado graúdo (aproximadamente 941 kg/m³). Em contrapartida, o teor de água (192 kg/m³) contribuiu para reduzir a previsão, assim como a ausência de superplastificante e de escória de alto forno nessa mistura específica. Esse exemplo é coerente com os padrões discutidos anteriormente, uma vez que cimento e idade elevados favorecem a resistência prevista, enquanto o excesso de água tende a reduzi-la, reforçando a interpretação global obtida pelas Figuras 4 e 5 com um caso concreto.

3.4. Otimização com Algoritmo Genético

Antes de apresentar os resultados da otimização, é importante retomar uma decisão de design que impacta diretamente sua interpretação. Reforço que, em todas as buscas realizadas pelo Algoritmo Genético, a idade de cura foi mantida fixa em 30 dias, não sendo tratada como uma variável livre de otimização junto com as demais. Essa escolha tem dois motivos. O primeiro é conceitual, uma vez que o objetivo da otimização proposta neste trabalho é encontrar a melhor proporção de materiais em uma formulação de concreto, e não decidir por quanto tempo o material deve curar, já que o tempo de cura não é uma decisão de dosagem, mas uma etapa posterior do processo construtivo. O segundo motivo é prático, já que, se a idade fosse deixada livre para o GA otimizar junto das demais variáveis, o algoritmo tenderia simplesmente a levá-la ao valor máximo observado no dataset (365 dias), dado que a resistência do concreto aumenta com o tempo de cura, o que trivializaria a busca e desviaria o foco da real questão de interesse, que é a composição da mistura. O valor de 30 dias foi escolhido por se aproximar do padrão de

28 dias amplamente utilizado na indústria para ensaios de resistência à compressão do concreto, funcionando como uma referência realista e comum de comparação.

A Tabela 4 resume os resultados das três buscas realizadas com o Algoritmo Genético, comparadas com a melhor amostra real observada no dataset.

Tabela 4. Comparação entre a melhor mistura observada no dataset e as misturas encontradas pelo Algoritmo Genético, com e sem restrições de domínio, e utilizando diferentes modelos como função de avaliação. A idade de cura foi fixada em 30 dias em todos os casos.

Origem da mistura	Resistência prevista/observada (MPa)
Melhor amostra do dataset	82.60
GA livre, avaliado pelo XGBoost	89.34
GA restrito, avaliado pelo XGBoost	84.26
GA livre, avaliado pela MLP	145.58

A busca livre guiada pelo XGBoost encontrou uma mistura com resistência prevista de 89.34 MPa, acima do máximo observado no dataset. A análise dessa mistura revelou que ela combina, simultaneamente, teores de cimento, escória e cinza volante próximos de seus respectivos máximos individuais, totalizando 881.4 kg/m³ de material cimentício, valor superior ao máximo observado em qualquer amostra real do dataset, que é de 640.0 kg/m³. A razão entre água e material cimentício da mistura sugerida (0.166) também ficou abaixo do mínimo histórico observado (0.235). Esses dois indicadores compostos evidenciam que, embora cada variável individualmente estivesse dentro do intervalo observado, a combinação das variáveis correspondia a uma região do espaço de composições sem apoio de dados reais de treino.

Ao impor restrições de domínio, limitando o total de material cimentício e a razão água/binder aos valores extremos observados no dataset, o GA restrito convergiu para uma resistência prevista de 84.26 MPa, apenas 1.66 MPa acima do máximo observado, com uma composição de proporções muito próxima da melhor mistura real conhecida, como ilustrado na Figura 7. Esse resultado indica que, dentro de uma região fisicamente plausível, o XGBoost guia a otimização de volta à vizinhança de soluções reais, reforçando que o padrão aprendido pelo modelo é consistente com o comportamento físico do concreto.

Por fim, ao repetir a busca livre utilizando a MLP como função de avaliação, o GA convergiu para uma resistência prevista de 145.58 MPa, valor consideravelmente mais distante da realidade do que o obtido com o XGBoost na mesma condição sem restrições. A composição encontrada levou praticamente todas as variáveis aos seus valores extremos observados no dataset. Esse resultado sugere uma diferença estrutural entre os dois modelos diante de extrapolação, uma vez que modelos baseados em árvores tendem a limitar suas previsões a valores próximos aos observados durante o treinamento, enquanto a MLP, por não possuir esse tipo de limitação na camada de saída, pode extrapolar de forma mais acentuada quando a entrada se afasta da distribuição de treino.




Figura 7. Comparação entre a melhor mistura observada no dataset, a mistura encontrada pelo GA livre e pelo GA restrito, com a composição percentual de cada variável indicada dentro de cada barra. Autoria própria.

4. Lições Aprendidas

O desenvolvimento deste trabalho foi uma boa oportunidade para revisar conceitos que eu já tinha visto na graduação, mas que ainda não tinha conseguido explorar com tanta profundidade, principalmente os algoritmos genéticos. Uma decisão que funcionou bem foi utilizar um dataset simples e já limpo. Com isso, foi possível concentrar mais tempo na comparação entre os modelos e na análise dos resultados, em vez de dedicar grande parte do trabalho ao tratamento dos dados. Também considero que a separação entre a validação cruzada, usada na escolha dos hiperparâmetros, e o conjunto de teste, utilizado apenas na avaliação final, foi importante para evitar que o processo de seleção acabasse influenciando a avaliação dos modelos.

Por outro lado, um dos principais problemas que encontrei durante o trabalho foi perceber que uma boa métrica de erro não é suficiente para garantir que o modelo esteja produzindo resultados úteis em qualquer situação. Isso ficou mais evidente na etapa do algoritmo genético. Inicialmente, uma previsão de resistência mais alta poderia parecer simplesmente um resultado melhor. Porém, ao analisar as misturas encontradas pelo GA, ficou claro que algumas delas estavam em regiões pouco representadas ou até sem representação no dataset. A comparação do total de material cimentício e da razão água/binder ajudou a identificar esse problema, que não seria percebido apenas olhando os limites individuais de cada variável.

Se eu refizesse o trabalho, tentaria considerar essas restrições desde o início da etapa de otimização. Isso evitaria que fosse necessário primeiro observar uma solução

claramente suspeita para depois investigar o motivo. Também seria interessante utilizar alguma medida que indique o quanto uma mistura encontrada pelo GA está próxima das amostras utilizadas no treinamento. Dessa forma, seria possível ter uma indicação mais direta de quando o algoritmo está procurando uma solução dentro de uma região conhecida e quando está levando o modelo para uma região de extrapolação.

De forma geral, considero que o trabalho cumpriu bem o objetivo da disciplina e também foi importante para meu aprendizado. Foi possível passar por diferentes etapas, desde a preparação dos dados e treinamento dos modelos até a interpretação das previsões com SHAP e a utilização dos modelos como função de avaliação de um algoritmo genético. Ao longo desse processo, também ficou claro que utilizar técnicas mais complexas não significa necessariamente obter um resultado melhor. Neste dataset, por exemplo, o XGBoost apresentou desempenho superior à MLP.

Também não considero que a principal contribuição do trabalho esteja na combinação de MLP, XGBoost, SHAP e algoritmo genético, já que essa combinação de técnicas já aparece em outros trabalhos sobre previsão da resistência do concreto. O aspecto que considero mais interessante foi poder observar, de forma prática, o que acontece quando um modelo preditivo é utilizado para otimizar uma variável sem considerar as características da região em que ele foi treinado. A diferença entre os resultados obtidos com a MLP e o XGBoost também mostrou que esse problema pode variar bastante dependendo do modelo utilizado. No final, a principal lição que levo deste trabalho é que uma previsão não deve ser avaliada apenas pelo valor da métrica de desempenho. É necessário também verificar se o resultado faz sentido dentro dos dados e do problema que está sendo estudado.

Reprodutibilidade

O código completo utilizado neste trabalho, incluindo o notebook com todas as etapas descritas, está disponível em: Repositório Github do Projeto.

<https://github.com/andrearacaetano/study-of-mlp-and-genetic-algorithm-with-a-cement-dataset>

Declaração de Uso de Inteligência Artificial

Ferramentas de inteligência artificial foram utilizadas neste trabalho de forma pontual e auxiliar, restritas a três finalidades específicas: apoio na identificação e correção de erros básicos de implementação em trechos de código, revisão de erros de português no texto do relatório, e geração do esquema ilustrativo apresentado na Figura 1. As decisões metodológicas, a análise crítica dos resultados e as conclusões apresentadas neste relatório são de responsabilidade do autor.

Referências

- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM.
- Elhishi, S., Elashry, A. M., and El-Metwally, S. (2023). Unboxing machine learning models for concrete strength prediction using xai. *Scientific Reports*, 13(1).
- Elshaarawy, M. K., Alsaadawi, M. M., and Hamed, A. K. (2024). Machine learning and interactive gui for concrete compressive strength prediction. *Scientific Reports*, 14(1).
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2nd edition.
- I-Cheng Yeh (1998). Concrete compressive strength.
- Jin, Y. (2011). Surrogate-assisted evolutionary computation: Recent advances and future challenges. *Swarm and Evolutionary Computation*, 1(2):61–70.
- Kingma, D. P. and Ba, J. (2015). Adam: A method for stochastic optimization. In *3rd International Conference on Learning Representations (ICLR)*.
- Mehta, P. K. and Monteiro, P. J. M. (2014). *Concrete: Microstructure, Properties, and Materials*. McGraw-Hill Education, New York, 4th edition.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., and Chintala, S. (2019). Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32*, pages 8024–8035. Curran Associates, Inc.
- Prechelt, L. (1998). Early stopping – but when? In *Neural Networks: Tricks of the Trade*, volume 1524 of *Lecture Notes in Computer Science*, pages 55–69. Springer.
- Shapley, L. S. (1953). A value for n-person games. In Kuhn, H. W. and Tucker, A. W., editors, *Contributions to the Theory of Games II*, pages 307–317. Princeton University Press, Princeton.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958.
- Yeh, I.-C. (1998). Modeling of strength of high-performance concrete using artificial neural networks. *Cement and Concrete Research*, 28(12):1797–1808.